

Исследование влияния преобразований целевой переменной на качество моделей прогнозирования временных рядов

Исследование влияния преобразований целевой переменной на качество моделей прогнозирования временных рядов.....	1
Постановка задачи и гипотеза.....	1
Описание набора данных и предобработка.....	3
Методология: кластеризация и валидация.....	4
Протокол валидации.....	7
Описание экспериментов и моделей.....	9
Ход обучения и технические особенности.....	15
Анализ результатов и выводы.....	17
Анализ дифференцирования (diff) и проблема экстраполяции деревьев... 18	
Общая оценка моделей по кластерам.....	19
Анализ логов обучения CatBoost.....	20
Оценка распределение MASE.....	21
Оценка провала Vox-Cox.....	21
Финальный вывод по гипотезе.....	22
Графики из jupyter-ноутбука (раздел выводов) и обучение CatBoost.....	23

Постановка задачи и гипотеза

Цель проекта: Определить, какие преобразования временных рядов наиболее эффективны для различных структурных типов данных при использовании как классических статистических моделей, так и современных градиентных бустингов.

Гипотеза: Предполагается, что не существует универсального преобразования. Стабилизация дисперсии (Vox-Cox) должна показывать лучшие результаты для рядов с выраженной гетероскедастичностью, в то

время как дифференцирование (Differencing) будет эффективнее для рядов с сильным линейным трендом. Глобальные модели (CatBoost) выиграют от стандартизации внутри преобразований больше, чем локальные модели.

Ограничения: рассматриваются только ежедневные данные (M4 Daily).

- 1) Горизонт прогнозирования фиксирован: 14 дней, историческое окно - 30 дней.
- 2) Дата начала сэмплируемых временных рядов обрезана до 2010-01-01, поскольку в 2008-2009 году преобразования в связи с большой волатильностью данных при кризисном структурном сдвиге привели бы к взрывным\близким к нулю значениям на период кризиса с соответствующим занижением более стабильных периодов, которые являются более оптимальными для определения тренда и сезонности.
- 3) Поскольку ряды с ежедневными данными, сезонность была выбрана еженедельная, поскольку моделируются в том числе статистические подходы. В M4 по итогам анализа нельзя выявить четкую сезонную структуру, в связи с чем неделя является оптимальным и широко применяемым подходом в прогнозировании дневных данных.
- 4) Глобальная модель обучается в рамках одного кластера (Cluster-based Global Model), в качестве признаков выделены лаги по значению и айди ряда, остальные признаки были опущены в связи с постановкой гипотезы - рассматривается эффект преобразования ряда, дополнительные признаки могут исказить его с учетом специфики библиотеки CatBoost.
- 5) Для обучения CatBoost использовались параметры с 1000 итерациями и ограничением по ранней остановке по 50 итерациям -

поскольку модель была обучена в сжатые строки, такая постановка параметров могла привести к недообучению, что тем не менее не противоречит постановке гипотезы, так как вариативность эффекта разных преобразований заметна в том числе и на глобальной модели и в случае недообучения.

В анализе автор ссылается на выводы, представленные в `analysis_results.ipynb`. Структура репозитория и способ запуска проекта представлены в файле `README.md`.

Описание набора данных и предобработка

Для экспериментов выбран набор данных M4 Dataset (Daily). Из него случайным образом просемплировано 200 временных рядов (с параметром `random_state=42` для всех модулей, где требуется рандомизация). Этот объем является репрезентативным для проверки гипотез, сохраняя при этом разумную скорость проведения кросс-валидации.

Этапы предобработки (предполагаемый):

- 1) **Синхронизация:** Все ряды приведены к единой частоте (Daily).
- 2) **Обработка пропусков:** Использована линейная интерполяция (`backfill/forward fill`).
- 3) **Очистка:** Удалены дубликаты индексов.
- 4) **Стабилизация:** Для корректной работы преобразования Вох-Сох, требующего строго положительных данных, ко всем значениям был применен минимальный положительный сдвиг в случаях, если в данных присутствовали нули или отрицательные значения.

Результат: поскольку датасет М4 содержит только ненулевые положительные значения (по крайней мере, при семплировании), данные методы предобработки оказались мерой предостережения от ошибок. Лог обработки представлен ниже (см. jupyter-ноутбук):

Загрузка и фильтрация данных (Старт: 2010-01-01, Мин. длина: 150)

Отчет по предобработке датасета (отсечение до 2010-01-01):

Всего рядов собрано: 200

Рядов с пропусками внутри: 0

Рядов со сдвигом отрицательных/нулевых значений: 0

Мин. длина ряда: 150 дней

Методология: кластеризация и валидация

Вместо использования алгоритмов на основе сырых данных (например, метрики DTW), был применен подход **Feature-based Clustering**. Для каждого временного ряда с помощью библиотеки `tsfeatures` были извлечены следующие статистические признаки:

- **Trend и Seasonality:** сила тренда и сезонности.
- **Entropy:** сложность и степень непредсказуемости ряда.
- **Nonlinearity:** степень нелинейности структуры.
- **Stability и Lumpiness:** стабильность дисперсии и наличие резких локальных всплесков.

Обоснование выбора признаков: Данные признаки выбраны в связи со спецификой гипотезы. Цель исследования - оценить влияние преобразований. Эти трансформации созданы для борьбы с конкретными

проблемами временных рядов: гетероскедастичностью, нестационарностью и сильным шумом. Кластеризация по таким признакам как lumpiness, trend и stability позволяет сгруппировать ряды именно по их статистической структуре (характеру проблем), а не просто по внешней схожести формы, как это сделал бы DTW. Это позволяет сделать точные выводы о том, какое преобразование лучше всего корректирует конкретный тип ряда.

Обоснование сезонности (seasonality=7): На этапе разведочного анализа данных (EDA) были изучены графики автокорреляционной (ACF) и частично автокорреляционной (PACF) функций (см. в jupyter-ноутбуке). Анализ коррелограмм не выявил сезонных пиков, однако при углублении в годовичные данные можно наблюдать стандартные для еженедельной сезонности колебания. Учитывая природу используемого датасета (ежедневные данные M4 Daily), это может указывать на наличие по крайней мере слабой недельной сезонности, обусловленной человеческим фактором (разница в активности между будними и выходными днями). На основании этого параметр сезонности был зафиксирован на уровне seasonality=7 для настройки статистических моделей (AutoARIMA, AutoETS) и для корректного расчета метрики MASE.

Алгоритм и интерпретация кластеров: Был использован алгоритм иерархической агломеративной кластеризации с методом связи Ward (для минимизации внутрикластерной дисперсии). Оптимальное число кластеров $k=3$ было определено на основе оценки силуэта и исследовательской логики. Хотя оптимальное количество кластеров по метрике являлось равной двум, для вариативности эксперимента были подобраны три кластера, два из которых являются схожими по характеристикам, однако имеют расхождения в признаках, по которым принято разграничивать типы временных рядов.

График силуэт-сбора:




Таблица с оценкой кластеров по признакам:

Распределение:

cluster

0 125

1 40

2 35

cluster	0	1	2
hurst	0.986299	0.819824	1.028830
stability	0.989329	0.960137	0.999793
trend	0.995276	0.982922	0.998392
nonlinearity	0.037041	0.182361	0.035518
lumpiness	0.002818	0.083173	0.000045
entropy	0.276056	0.394236	0.210504

Анализ распределения признаков внутри групп позволил интерпретировать полученные кластеры следующим образом:

- **Кластер 0 (Стабильные ряды):** Четкие тренды (Trend: 0.995), но с заметным присутствием локального шума (Entropy: 0.276). Нелинейность крайне низкая. Ряды хорошо читаются, но содержат локальные колебания. Похож на второй кластер, но более зашумленный - вероятно, CatBoost будет лучше подбирать паттерны под него.
- **Кластер 1 (Шумные ряды с выбросами):** Самые трудные для прогнозирования ряды с высокой долей неопределенности. Лидер по нелинейности (0.182) и гетероскедастичности. Дисперсия скачет во времени (Lumpiness: 0.083). Тренд заметно слабее (Hurst: 0.819). Классические модели могут не справиться с данными рядами без серьезной трансформации.
- **Кластер 2 (Трендовые и нелинейные ряды):** Максимальная предсказуемость. Идеально ровные и стабильные тренды (Trend: 0.998, Stability: 0.999), сильная персистентность (Hurst больше 1). Минимальный шум и практически нулевая скачкообразность дисперсии (Lumpiness ок. 0). Скорее всего будет легко прогнозироваться классическими стат. моделями.

Протокол валидации

Для корректной и честной оценки качества моделей в рамках данного исследования был реализован протокол Walk-Forward Validation с тремя фолдами ($n_splits=3$).

Механика: Алгоритм последовательно отрезает тестовые участки с конца временного ряда, двигаясь назад в прошлое на размер горизонта прогнозирования ($horizon=14$).

- Фолд 1: Модель обучается на всех исторических данных, кроме последних 42 дней. Тестирование происходит на отрезке [N-42:N-28].
- Фолд 2: В обучающую выборку добавляются новые 14 дней. Тестирование сдвигается вперед на отрезок [N-28:N-14].
- Фолд 3: Модель обучается на всем доступном ряде до последних 14 дней. Тестирование проводится на самом свежем участке [N-14:N].

Такой подход позволяет протестировать устойчивость моделей в разные периоды времени и имитировать реальный процесс ежедневного переобучения пайплайна в продакшене.

Защита от утечек данных: В пайплайне реализована строгая изоляция:

- 1) Изоляция трансформаций. Класс-трансформер (TimeSeriesTransformer) вызывается и обучается (метод `.fit()`) строго на тренировочной части фолда. Все статистические параметры (лямбда для Вох-Сох, среднее, стандартное отклонение и квантильные границы для клиппинга) вычисляются исключительно на исторических данных. Это гарантирует, что трансформации не подстраиваются под амплитуду или дисперсию будущих значений тестового сета.
- 2) Изоляция таргета. Окно прогноза (14 дней) отделяется от ряда на самом первом этапе генерации индексов. Модель никогда не видит эти значения до момента подсчета метрик.
- 3) Изоляция базового уровня. Для расчета метрики MASE (Mean Absolute Scaled Error) ошибка наивной модели вычисляется только

на обучающем отрезке фолда, чтобы масштаб ошибки не зависел от тестовых данных.

Внутренняя валидация глобальной модели (Early Stopping):

Градиентный бустинг (GlobalCatBoostMIMO), использующий авторегрессионные окна (лаги) в качестве признаков, имеет высокую склонность к переобучению - модель может просто запомнить тренировочную выборку. Чтобы предотвратить это без использования тестового сета, применяется дополнительное внутреннее разбиение.

Внутри каждого обучающего фолда последние 10% сгенерированных временных окон (матрицы X и вектора Y) отделяются в отдельный валидационный сет (`eval_set`). Деревья CatBoost обучаются на оставшихся 90% окон, а качество проверяется на этих 10%. Включен механизм ранней остановки (`early_stopping_rounds=50`): если в течение 50 итераций метрика MultiRMSE на валидационном сете перестает улучшаться, процесс обучения принудительно прерывается.

Описание экспериментов и моделей

Для проверки гипотезы о влиянии предобработки на качество прогнозирования было реализовано сравнение четырех подходов к трансформации целевой переменной. Все преобразования изолированы внутри обучающей выборки каждого фолда (строго до момента `split_idx`), чтобы исключить любую утечку данных.

Сравниваемые подходы:

- 1) **None:** Использование исходной шкалы (бейзлайн-преобразование).
- 2) **Log1p:** Логарифмирование. Классический метод стабилизации рядов с экспоненциальным ростом и гетероскедастичностью.

3) **Diff:** Дифференцирование первого порядка. Осуществляет переход от абсолютных значений к приращениям, делая ряд с выраженным линейным трендом стационарным по среднему. При обратном преобразовании прогноз восстанавливается через кумулятивную сумму (`np.cumsum`), прибавленную к последнему известному значению трейна.

4) **Box-Cox с робастной инверсией:** Обобщенное степенное преобразование, которое является центральным фокусом эксперимента.

Реализация Box-Cox: Стандартная реализация преобразования в библиотеках обладает большим недостатком при работе с прогнозированием: склонностью к экспоненциальному взрыву при обратном преобразовании (`inverse transform`). Если модель предсказывает аномально высокое значение в трансформированном пространстве, обратное возведение в степень приводит к переполнению типа `float64` (появлению бесконечностей `inf` или `NaN`), что полностью ломает расчет метрик (RMSE, MASE) на всем фолде.

Для решения этой проблемы был разработан кастомный класс `TimeSeriesTransformer`, включающий многоуровневую систему защиты:

1) **Стандартизация пространства:** Сразу после вычисления оптимального параметра лямбда (с помощью оценки максимального правдоподобия `boxcox_poptmax`) и применения трансформации, ряд подвергается Z-нормализации. Вычисляются среднее и стандартное отклонение трансформированного трейна. Это критически важный шаг для глобальной модели (CatBoost MIMO), так как он приводит признаки всех временных рядов (независимо от их исходного

масштаба продаж/посещений) к единому распределению, спасая бустинг от проблемы `unsafe target value`.

- 2) **Динамическое ограничение (робастный клиппинг):** Вместо жестких ограничений вычисляется область допустимых значений (ОДЗ) динамически для каждого ряда. На этапе `fit` извлекаются 1-й и 99-й перцентили трансформированного ряда. К этому диапазону добавляется 50% запас (`margin`). Перцентили используются вместо абсолютных минимумов и максимумов для защиты ОДЗ от случайных единичных выбросов в исторической выборке. На этапе прогноза все предсказания модели принудительно обрезаются (`np.clip`) по этим границам перед обратным преобразованием. Это позволяет модели прогнозировать новые максимумы (продолжать тренд), но физически блокирует вылет в бесконечность.
- 3) **Защита границ:** Математически обратное преобразование обязано быть строго больше нуля, иначе операция извлечения корня (при дробных `лямбда`) приведет к ошибке. В коде реализована жесткая граница `boundary=-1.0/self.lambda_`. Если прогноз модели пересекает этот предел, он искусственно возвращается в безопасную зону с помощью минимального сдвига (`eps=1e-8`).
- 4) **Закрытие сбоев наивным прогнозом:** Если, несмотря на все защиты, алгоритм инверсии не справляется, финальный рубеж функции `inverse_transform` заменяет любые `NaN` или `inf` на последнее известное значение из трейна (`self.last_val`). С научной точки зрения это означает, что если сложная модель выдает неадекватный (взорвавшийся) прогноз, алгоритм мягко штрафует её метрики, приравнивая её прогноз к простейшему `Naive Baseline`, тем самым сохраняя целостность всего пайплайна валидации.

5) Обработка константных рядов: Для временных рядов, представляющих собой прямую линию (где все значения равны), любые попытки масштабирования приводят к делению на ноль, а Box-Cox теряет смысл. В класс встроен детектор констант (`np.allclose(series, series[0])`). Если такой ряд обнаружен, трансформации отключаются, а в качестве предсказания жестко возвращается сама эта константа. Однако для специфики датасета M4 это скорее мера предупреждения ошибки.

Набор моделей:

Для оценки влияния преобразований на качество прогнозирования, в пайплайн включены две разные парадигмы обучения: семейство локальных статистических моделей и глобальная модель на основе градиентного бустинга.

- 1) Локальные бейзлайны: Для установления нижней границы качества (baseline), которую могут побить более сложные алгоритмы, используются две наивные модели: Naive (Наивный прогноз): Предсказывает последнее известное значение временного ряда на весь горизонт прогнозирования. Эффективен для рядов типа случайное блуждание. Seasonal Naive (Сезонный наивный прогноз): Предсказывает значение, которое наблюдалось ровно один сезон назад (с шагом 7 дней). Модель служит жестким бейзлайном для рядов с выраженной недельной цикличностью.
- 2) Умные статистические модели (StatsForecast) В качестве классического подхода применяются модели, которые обучаются индивидуально для каждого временного ряда (AutoArima, AutoETS, AutoTheta).

Выбор версий с автоматическим подбором гиперпараметров является не только средством поиска лучшей модели, но и важным аналитическим инструментом для оценки самих трансформаций. Встроенные алгоритмы перебирают параметры (например, порядок авторегрессии p , степень интегрирования d , порядок скользящего среднего q для ARIMA) и выбирают оптимальные на основе информационных критериев.

Отслеживая, как меняются выбранные гиперпараметры в зависимости от примененного преобразования, можно показать эффективность предобработки. Например:

- Если дифференцирование (Diff) действительно убирает нестационарность, ожидается, что модель AutoARIMA массово обнулит параметр d .
- Если преобразование Box-Cox успешно подавляет гетероскедастичность (рост дисперсии), алгоритм AutoETS должен изменить тип ошибки и сезонности с мультипликативного (M) на аддитивный (A), так как ряд становится линейным.

В качестве ML-подхода реализована единая глобальная модель на базе градиентного бустинга CatBoost. Модель обучается одновременно на всех временных рядах внутри выделенного кластера, пытаясь найти универсальные паттерны поведения.

Механизм авторегрессионных окон: Обучение строится на подходе скользящего окна. Каждый временной ряд нарезается на множество перекрывающихся отрезков. В качестве признаков (фичей) выступают 30 последних исторических значений ряда (лагов). При этом сезонные или иные календарные лаги не выводятся - поскольку модель может сама уловить паттерны, привязанные к календарным дням, в процессе обучения,

а также эффект сезонности на основе EDA либо не наблюдается, либо очень слабый.

Архитектура MIMO и функция потерь MultiRMSE: Использована стратегия MIMO. В отличие от рекурсивного прогноза, модель предсказывает весь вектор из 14 будущих дней за один проход. Для оптимизации такой архитектуры выбрана функция потерь MultiRMSE. Она минимизирует евклидово расстояние между предсказанным 14-мерным вектором и фактическим вектором ответов. Это заставляет деревья решений оптимизировать не отдельные точки прогноза, а совместную траекторию будущего ряда, учитывая зависимости дней друг от друга.

Категориальный признак ts_id: Главная проблема глобальных моделей - потеря индивидуальности рядов (например, разный базовый уровень спроса). Для решения этой проблемы, помимо 30 числовых лагов, в вектор признаков каждого окна добавляется строковый идентификатор конкретного временного ряда (ts_id). CatBoost обрабатывает его с помощью встроенного механизма Target Encoding для категориальных фичей. Это позволяет бустингу строить отдельные ветви для специфичных рядов, запоминая их индивидуальные характеристики, но при этом используя общую память кластера для выявления глобальных трендов.

Обоснование метрик

Для оценки выбраны три метрики, дополняющие друг друга:

- 1) **sMAPE (Symmetric Mean Absolute Percentage Error):** Позволяет сравнивать ряды разного масштаба. Используется модифицированная версия, устойчивая к малым значениям в знаменателе.

2) **MASE (Mean Absolute Scaled Error):** Критическая метрика для задачи. Показывает, насколько модель лучше (или хуже) простого прогноза. Если $MASE > 1$, модель бесполезна.

3) **RMSE (Root Mean Squared Error):** Штрафует за крупные ошибки и выбросы, что важно для оценки стабильности трансформаций (особенно инверсии Box-Cox).

Данные метрики являются стандартными для оценок моделей в задаче временных рядов, при этом для текущей гипотезы нет необходимости подбора оптимальных по метрикам моделей - достаточно иметь сравнимость по преобразованиям для каждой модели. В свою очередь, разброс метрик по моделям и качество самих моделей внутри каждого преобразования служит **дополнительным инсайтом к тому, модель с каким преобразованием для задачи прогнозирования рядов датасета M4 в посткризисном разрезе наиболее оптимальна.**

Ход обучения и технические особенности

Для обеспечения воспроизводимости и автоматизации расчетов весь процесс исследования был объединен в единый вычислительный пайплайн. Ход выполнения экспериментов строго структурирован и состоит из следующих последовательных этапов:

Этап 1. Загрузка данных и кластеризация: Пайплайн инициализируется с загрузки выборки из 200 временных рядов датасета M4 Daily. Для каждого ряда извлекаются статистические признаки с учетом недельной сезонности. Признаки масштабируются, после чего ряды распределяются по заданному количеству кластеров. Формируется словарь, где ключом является номер кластера, а значением - список относящихся к нему рядов.

Этап 2. Инициализация валидатора: Создается объект WalkForwardValidator, в который передаются глобальные параметры эксперимента: горизонт прогнозирования (14 дней), количество фолдов (3), сезонность (7) и размер исторического окна для признаков (30). Этот валидатор отвечает за нарезку данных на обучающие и тестовые участки без утечек информации.

Этап 3. Основной цикл экспериментов: Запускается вложенный цикл. На верхнем уровне алгоритм итерируется по каждому сформированному кластеру. Внутри каждого кластера происходит итерация по списку выбранных математических преобразований: исходная шкала (none), логарифмирование (log1p), преобразование Box-Cox (boxcox) и дифференцирование (diff).

Этап 4. Обучение глобальной модели: Для каждой связки "Кластер+Трансформация" сначала запускается кросс-валидация глобальной модели CatBoost. Модель обучается одновременно на всех рядах текущего кластера. После завершения обучения скрипт логирует фактическое количество построенных деревьев (которое определяется механизмом Early Stopping) и лучший показатель функции потерь MultiRMSE на валидационной выборке. Обученная модель сериализуется и сохраняется на жесткий диск (в формате .joblib) для возможности дальнейшего использования без переобучения.

Этап 5. Обучение локальных статистических моделей: Следом за глобальной моделью для той же связки "Кластер+Трансформация" запускается расчет локальных бейзлайнов и умных стат. моделей (Naive, SeasonalNaive, AutoTheta, AutoETS, AutoARIMA) через библиотеку StatsForecast. В отличие от CatBoost, эти алгоритмы обучаются

изолированно для каждого отдельного ряда в кластере, но их результаты собираются в общий массив.

Этап 6. Агрегация и сохранение метрик: В процессе работы пайплайна результаты всех фолдов, моделей и трансформаций (включая значения sMAPE, MASE, RMSE и выбранные гиперпараметры для Auto-моделей) накапливаются в едином списке. По завершении всех циклов эти данные конвертируются в сводную таблицу Pandas и сохраняются в итоговый файл metrics.csv, который в дальнейшем используется для построения графиков и аналитических выводов в jupyter-ноутбуке.

Анализ результатов и выводы

Графики доступны либо в jupyter-ноутбуке, либо ниже в последнем

Влияние преобразований на структуру ряда

Классические статистические модели (AutoARIMA, AutoETS, AutoTheta) выступают в эксперименте не только как инструменты анализа структуры данных.

- **Идентификация гетероскедастичности:** На исходной шкале (none) алгоритм AutoETS в 272 случаях выбрал мультипликативные модели: ETS(M,N,N) (206) и ETS(M,A,N) (66). Это математически подтверждает, что ряды датасета M4 обладают выраженной гетероскедастичностью - их дисперсия растет пропорционально уровню ряда.
- **Аддитивный эффект преобразований:** Применение преобразований радикально меняет поведение алгоритмов. Мультипликативные компоненты AutoETS исчезают почти полностью. Доминирующей становится аддитивная модель

ETS(A,N,N) (379 случаев для log1p как пример). Это доказывает, что все трансформации успешно линеаризовал ряды и стабилизировал дисперсию.

- **Реакция AutoARIMA на diff:** На исходных данных AutoARIMA чаще всего использует сезонное интегрирование и скользящее среднее $ARIMA(0,0,0,0,1,1,0)$. Однако при подаче дифференцированных рядов, алгоритм массово перестраивается на $ARIMA(0,0,0,0,1,0,0)$ (251 случай) и $ARIMA(0,1,0,0,1,0,0)$. Поскольку ряд уже стал стационарным (лишен тренда из-за diff), AutoARIMA отключает или меняет внутренние механизмы компенсации тренда, чтобы не допустить over-differencing.

Анализ дифференцирования (diff) и проблема экстраполяции деревьев

Результаты CatBoostMIMO вскрывают уязвимость градиентного бустинга - **неспособность к экстраполяции.**

- **Провал на none и log1p:** На сырых данных и логарифмах CatBoost показывает катастрофические результаты: MASE от 4.40 до 9.18 на none и от 1.27 до 2.23 на log1p. RMSE достигает огромных значений (до 1525). Причина: деревья решений не умеют предсказывать значения, выходящие за границы обучающего окна. Если тренд идет вверх, CatBoost упирается в потолок исторического максимума и выдает горизонтальный прогноз.
- **Спасительный diff:** Переход к дифференцированию первого порядка кардинально меняет картину для бустинга. Предсказывая не абсолютные значения, а приращения, CatBoost возвращается в эффективный режим. Его MASE падает до 0.96 (Кластер 0), 0.92 (Кластер 1) и 1.11 (Кластер 2).

- **Конфликт diff и стат. моделей:** Ожидаемый инсайт заключается в том, что diff ухудшает работу AutoARIMA и AutoETS (их MASE возрастает с 0.95 до 2.3-2.8). Эти модели созданы для работы с абсолютными значениями и имеют внутренние механизмы работы с трендом. Внешнее дифференцирование с последующей искусственной кумулятивной суммой (cumsum) накапливает ошибку прогноза с каждым шагом горизонта.

Общая оценка моделей по кластерам

Анализ метрики MASE позволяет определить оптимальные стратегии для каждого типа рядов:

- 1) **Кластер 2 (Трендовые, ровные ряды): Статистические модели (AutoARIMA/AutoETS) с none или log1p (MASE 1.10-1.11).**
 - На идеально ровных трендах простые модели работают отлично. Глобальный CatBoost (даже с diff) справляется здесь чуть хуже (MASE 1.11), так как ему сложнее уловить идеальную гладкость локального тренда среди всего кластера.
- 2) **Кластер 0 (Стабильные тренды с шумом): AutoARIMA на none (MASE 0.95) и CatBoost на diff (MASE 0.96).**
 - Оба подхода пробивают бейзлайн. CatBoost начинает получать преимущество за счет возможности выуживать паттерны из локального шума на базе данных всего кластера.
- 3) **Кластер 1 (Шумные ряды с хаотичной дисперсией): CatBoost_MIMO с трансформацией diff (MASE 0.92).**
 - Статистические модели здесь теряются (их MASE падает до 0.93-1.05, а sMAPE высокое). Глобальная модель, обучаясь на

множестве шумных рядов одновременно, находит общие нелинейные закономерности скачков, которые недоступны локальной AutoARIMA.

Анализ логов обучения CatBoost

Логи функции потерь и количества построенных деревьев до срабатывания остановки дают понимание о признаковом пространстве:

- **Обучение на none (loss: 1289-3135, trees: 150-340):** Высокий лосс закономерен - это MultiRMSE в абсолютных значениях сырых продаж. Модель останавливается относительно быстро, так как быстро упирается в предел своей способности экстраполировать тренд.
- **Обучение на log1p (loss: 0.16-0.43, trees: 194-705):** Лосс минимален из-за сжатия шкалы (логарифмы). На кластере 0 алгоритм построил самое большое число деревьев - **705**. Это означает, что log1p сделал ландшафт функции потерь очень гладким, позволив градиентному спуску долго и аккуратно находить микро-паттерны, не переобучаясь.
- **Обучение на diff (loss: 390-1296, trees: 36-200):** Модель останавливается очень рано (на кластере 1 всего за **36 деревьев**). Причина: стационарный ряд приращения содержит гораздо меньше сигнала. Бустинг сразу схватывает базовую логику приращений, и дальнейшее построение деревьев ведет только к переобучению на шуме. Ранняя остановка здесь спасает модель от переобучения, что привело к лучшему MASE (0.92).

- **Провал boxcox (loss: 0.7-8.9, Trees: 58-273):** Ранняя остановка (58 деревьев на кластере 1) говорит о том, что валидационный лосс начинает расти почти сразу из-за экстремальной нестабильности пространства признаков.

Оценка распределение MASE

График подтверждает табличные выводы:

- 1) **Линия MASE=1.0:** Четко отделяет успешные конфигурации от провальных.
- 2) **Группировка none и log1p:** Ящики AutoARIMA, AutoETS и AutoTheta лежат плотной, компактной группой на уровне 1.0 или чуть ниже. Усов (разброса) почти нет, что говорит о высокой стабильности локальных моделей. CatBoost на этих блоках отсутствует (его ящики находятся далеко за верхней границу оси Y).
- 3) **Группировка diff:** Зеленый ящик CatBoost опускается к красной линии, показывая плотное и предсказуемое распределение без экстремальных хвостов.
- 4) **Секция boxcox:** Ящики растянуты, медианы смещены вверх. Это визуальное подтверждение того, что Box-Cox вносит непрогнозируемый разброс.

Оценка провала Box-Cox

Одна из частей исходной гипотезы предполагала, что Box-Cox покажет лучшие результаты для рядов с гетероскедастичностью. **Эта гипотеза полностью опровергнута текущим экспериментом.**

Несмотря на квантильную защиту области допустимых значений в трансформере, инверсия на ежедневных зашумленных данных датасета M4 раздувает ошибки прогноза. MASE улетает до значений 2.65-9.18. Метод `log1p` оказался более безопасным и надежным средством для стабилизации дисперсии в автоматизированных пайплайнах.

Финальный вывод по гипотезе

Цель проекта реализована. Удалось определить эффективность преобразований для каждой модели.

Пункты гипотезы:

- 1) Не существует универсального преобразования - **верно**. Для локальных статистических моделей дифференцирование дает негативный эффект, а для глобального бустинга - крайне позитивный.
- 2) Вох-Сох покажет лучшие результаты для гетероскедастичности - **не верно**. Вох-Сох оказался слишком нестабильным на этапе инверсии прогноза. С задачей стабилизации дисперсии эффективнее справилось преобразование `log1p`.
- 3) Diff эффективнее для рядов с линейным трендом - **почти верно**. Это справедливо только для градиентных бустингов, так как решает их архитектурную проблему с экстраполяцией. Классические модели справляются с трендом без предварительного внешнего дифференцирования.
- 4) Глобальные модели выиграют от стандартизации внутри преобразований больше, чем локальные - **верно**. Переход к приращениям (diff) показал CatBoost как самую точную модель на

самом сложном кластере данных (MASE 0.92 на Кластере 1). В то время как внешние преобразования для локальных моделей не дали радикальных скачков качества.

Таким образом, в посткризисном разрезе для стабильных трендов целесообразно использовать AutoARIMA с логарифмированием ($\log 1p$), а для сложных, волатильных и зашумленных рядов оптимальным выбором становится CatBoostMIMO с дифференцированием (diff) первого порядка.

Стоит уточнить главное ограничение результатов - поскольку в рядах нет выраженного сезонного эффекта, метрика MASE может быть неоптимальной, так как основана на сравнении именно с сезонным наивным прогнозом. Однако это ограничение снимается результатами, которые показывают в том числе и другие бейзлайны, и сопоставлением всех моделей, включая наивные, по этой метрике. Также расхождения SeasonalNaive с прогнозом, вложенным в структуру расчета метрики MASE, объясняется библиотечной реализацией.

Остальные метрики были затронуты не напрямую в выводе, однако в анализе исследования на предмет эффективности преобразований участвовали на этапе оценки наиболее состоятельного метода и трансформера (в т.ч. согласуются с MASE).

Графики из jupyter-ноутбука (раздел выводов) и обучение CatBoost

Логи обучения:

Кластер 0 с none. СВ: 340 деревьев, Лосс: 1289.7378

Кластер 0 с log1p. СВ: 705 деревьев, Лосс: 0.1664

Кластер 0 с boxcox. СВ: 114 деревьев, Лосс: 2.3316

Кластер 0 с diff. СВ: 200 деревьев, Лосс: 441.4919

Кластер 1 с none. СВ: 195 деревьев, Лосс: 3135.6997

Кластер 1 с log1p. СВ: 347 деревьев, Лосс: 0.4330

Кластер 1 с boxcox. СВ: 58 деревьев, Лосс: 8.9930
 Кластер 1 с diff. СВ: 36 деревьев, Лосс: 1296.0384
 Кластер 2 с none. СВ: 157 деревьев, Лосс: 1299.3789
 Кластер 2 с log1p. СВ: 194 деревьев, Лосс: 0.1653
 Кластер 2 с boxcox. СВ: 273 деревьев, Лосс: 0.7128
 Кластер 2 с diff. СВ: 44 деревьев, Лосс: 390.8604

Общая таблица метрик:

transform		boxcox			diff			log1p			none		
		MASE	RMSE	sMAPE	MASE	RMSE	sMAPE	MASE	RMSE	sMAPE	MASE	RMSE	sMAPE
cluster	model												
0	AutoARIMA	2.65	415.49	6.94	0.95	181.83	2.33	0.96	183.91	2.35	0.95	181.76	2.33
	AutoETS	2.65	415.57	6.94	0.96	183.27	2.37	0.97	183.76	2.34	0.97	184.75	2.35
	AutoTheta	2.65	416.71	6.98	1.10	210.09	2.68	0.97	184.32	2.36	0.96	183.63	2.37
	CatBoost_MIMO	4.40	736.62	10.66	0.96	183.40	2.32	1.27	242.32	2.94	1.35	236.49	3.22
	Naive	2.65	416.87	6.94	2.61	520.63	6.23	0.97	185.20	2.35	0.97	185.20	2.35
	SeasonalNaive	2.85	452.50	7.44	1.38	256.61	3.35	1.19	227.36	2.88	1.19	227.36	2.88
1	AutoARIMA	6.11	886.57	22.59	1.05	214.35	2.86	1.01	205.19	2.87	1.05	216.96	2.90
	AutoETS	6.10	883.67	22.56	1.04	210.24	2.88	0.99	200.80	2.77	0.93	190.69	2.69
	AutoTheta	6.11	885.46	22.63	1.10	217.43	3.58	0.97	193.15	2.80	0.93	189.37	2.72
	CatBoost_MIMO	9.18	1525.39	31.69	0.92	185.94	2.67	2.23	431.75	5.74	1.92	350.74	5.63
	Naive	6.10	882.67	22.54	2.89	498.54	8.45	0.92	187.60	2.68	0.92	187.60	2.68
	SeasonalNaive	6.35	924.15	23.12	1.31	247.72	4.01	1.26	248.56	3.43	1.26	248.56	3.43
2	AutoARIMA	5.76	1069.43	14.54	1.11	219.06	2.35	1.12	222.71	2.37	1.11	218.65	2.36
	AutoETS	5.65	1059.80	14.40	1.11	217.89	2.39	1.10	217.32	2.33	1.10	216.75	2.34
	AutoTheta	5.77	1072.02	14.60	1.23	244.46	2.65	1.11	219.54	2.38	1.11	219.94	2.42
	CatBoost_MIMO	6.73	1178.48	16.25	1.11	214.44	2.34	1.39	253.88	2.95	1.43	243.98	3.13
	Naive	5.65	1059.09	14.40	2.64	480.43	5.35	1.10	215.42	2.33	1.10	215.42	2.33
	SeasonalNaive	5.86	1104.09	14.92	1.55	321.07	3.32	1.33	266.13	2.89	1.33	266.13	2.89

Стат. модели с автоподбором:

transform	boxcox	diff	log1p	none
auto_params				
ARIMA(0, 0, 0, 0, 1, 0, 0)	0.0	251.0	0.0	0.0
ARIMA(0, 0, 0, 0, 1, 1, 0)	239.0	0.0	242.0	270.0
ARIMA(0, 1, 0, 0, 1, 0, 0)	0.0	52.0	0.0	0.0
ARIMA(0, 1, 0, 0, 1, 1, 0)	70.0	0.0	62.0	55.0
ARIMA(1, 1, 0, 0, 1, 1, 0)	40.0	0.0	43.0	31.0
ARIMA(2, 2, 0, 0, 1, 0, 0)	0.0	43.0	0.0	0.0

transform	boxcox	diff	log1p	none
auto_params				
ETS(A,A,N)	26.0	0.0	0.0	0.0
ETS(A,Ad,N)	29.0	12.0	39.0	0.0
ETS(A,N,A)	0.0	25.0	0.0	0.0
ETS(A,N,N)	527.0	559.0	379.0	257.0
ETS(M,A,N)	0.0	0.0	0.0	66.0
ETS(M,N,N)	0.0	0.0	133.0	206.0

transform	boxcox	diff	log1p	none
auto_params				
DOTM	107.0	108.0	82.0	86.0
OTM	299.0	387.0	146.0	214.0
STM	193.0	105.0	336.0	285.0

Боксплоты на MASE:

